

LAPORAN PROYEK CASE-BASED REASONING (CBR)

ANALISIS PUTUSAN PERDATA PERBUATAN MELAWAN HUKUM (PMH) — PN BANDUNG

Mata Kuliah Penalaran Komputer — Sub CPMK 3 — Semester Genap 2025/2026

Keterangan	Isi
Domain Perkara	Perdata - Perbuatan Melawan Hukum (PMH)
Pengadilan	Pengadilan Negeri Bandung
Sumber Data	Direktori Putusan Mahkamah Agung RI
Repository	https://github.com/andika26ck/Case-Based-Reasoning-CBR-sederhana

Anggota Tim

Nama	NIM
Andika Candra Kurniawan	202310370311173
Ahmad Habibi	202310370311161

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Case-Based Reasoning (CBR) adalah paradigma kecerdasan buatan yang menyelesaikan masalah baru dengan cara mengambil (retrieve) kasus-kasus lama yang mirip dari sebuah case base, lalu menggunakan kembali (reuse) solusinya. Pendekatan ini sangat sesuai untuk domain hukum yang menganut prinsip kemiripan kasus (similar facts, similar rulings).

Proyek ini membangun sistem CBR sederhana berbasis Python untuk menganalisis putusan pengadilan perdata dengan jenis perkara Perbuatan Melawan Hukum (PMH) dari Pengadilan Negeri Bandung.

1.2 Tujuan

- Membangun case base dari minimal 30 putusan PMH yang bersih dan terstruktur.
- Merepresentasikan tiap putusan ke dalam metadata dan fitur teks.
- Membangun mekanisme retrieval untuk menemukan kasus termirip.
- Menggunakan kembali solusi (amar putusan) kasus lama untuk memprediksi keluaran kasus baru.
- Mengevaluasi performa model secara kuantitatif dan kualitatif.

1.3 Siklus CBR yang Diimplementasikan

Sistem mengikuti siklus 4R (Retrieve – Reuse – Revise – Retain):

- **Retrieve** — menghitung similarity query kasus baru dengan seluruh case base (TF-IDF + SVM/NB untuk klasifikasi; TF-IDF & BERT cosine untuk retrieval).
- **Reuse** — mengambil top-5 kasus termirip lalu menentukan solusi melalui majority vote / weighted similarity.
- **Revise** — (opsional) mengoreksi solusi bila diperlukan.
- **Retain** — (opsional) menyimpan kasus baru ke dalam case base.

BAB 2 DATASET DAN DOMAIN

2.1 Profil Data

Aspek	Keterangan
Domain perkara	Perdata - Perbuatan Melawan Hukum (PMH)
Pengadilan	PN Bandung
Total dokumen di-scraping	131
Dokumen valid (≥ 100 kata & keutuhan $\geq 50\%$)	90
Dokumen tidak valid	41 (40 di antaranya gagal ekstraksi / 0 kata)
Duplikasi nomor perkara	Tidak ada

2.2 Statistik Teks (dokumen valid)

- Rata-rata jumlah kata ± 9.170 ; median 4.789; maksimum 52.546.
- Kelengkapan metadata (no_perkara, tanggal_register, klasifikasi, amar, hakim_ketua, judul): 0% kosong.
- Nama penggugat berhasil diekstrak 88/90; nama tergugat 86/90.

2.3 Distribusi Label (decision_type)

Label hasil ekstraksi awal sangat timpang dan memiliki kelas yang sangat langka, sehingga digabungkan menjadi 3 kelas agar layak untuk stratified split dan pelatihan model.

Label awal	Jumlah	Label final	Jumlah
ditolak	58	ditolak	58
dikabulkan	14	dikabulkan	23
dikabulkan_sebagian	6	(gabung → dikabulkan)	
dikabulkan_seluruhnya	3	(gabung → dikabulkan)	
lainnya	8	lainnya	9
gugur	1	(gabung → lainnya)	

Distribusi tetap timpang (ditolak $\approx 64\%$), sehingga Accuracy saja kurang representatif; analisis menekankan macro-F1 dan confusion matrix.

BAB 3 METODOLOGI PER TAHAP CBR

Tahap 1 — Membangun Case Base (01_scraping.py)

- Scraping putusan dari Direktori MA RI menggunakan undetected-chromedriver (melewati proteksi bot) + requests/BeautifulSoup.
- Ekstraksi teks PDF menjadi plain text dengan pdfminer.six.
- Cleaning: penghapusan header/footer, normalisasi karakter, penurunan ke huruf kecil, dan tokenisasi.
- Validasi: penyaringan berdasarkan ambang jumlah kata dan skor keutuhan teks; QA otomatis (02_qa_check.py) memeriksa konsistensi, distribusi panjang, duplikasi, dan kelengkapan metadata.

- Output: data/raw/*.txt, data/processed/metadata_raw.csv, logs/qa_report.txt.

Tahap 2 — Case Representation (02_representation.py)

- Ekstraksi metadata: nomor perkara, tanggal, jenis perkara, pengadilan, hakim ketua, klasifikasi.
- Ekstraksi pihak: nama penggugat & tergugat (pola regex format putusan).
- Ekstraksi konten kunci: ringkasan fakta, argumen hukum, pasal yang dirujuk, amar putusan.
- Feature engineering: jumlah kata, jumlah token, panjang ringkasan/argumen, jumlah pasal dirujuk.
- Output: data/processed/cases.csv dan cases.json (90 record).

Tahap 3 — Case Retrieval (03_retrieval.py)

- Representasi vektor: TF-IDF (ngram 1-2, max_features=10000, min_df=2, sublinear_tf) → vocabulary akhir 2.094; serta BERT embedding all-MiniLM-L6-v2 (384 dimensi).
- Splitting data: 80% train / 20% test (72/18) dengan stratified split pada label final.
- Model: TF-IDF+SVM (LinearSVC), TF-IDF+Naive Bayes (MultinomialNB), TF-IDF+Cosine Similarity, dan BERT+Cosine Similarity.
- Fungsi retrieve(query, k) mengembalikan top-k case_id termirip berdasarkan cosine similarity.
- Output: model di models/, data/eval/queries.json (10 query uji), data/eval/retrieval_metrics.csv.

Tahap 4 — Case Solution Reuse (04_predict.py)

- Dari top-5 kasus termirip (retrieval ke data train saja), solusi diambil dari amar putusan.
- Algoritma prediksi: weighted similarity (bobot = skor similarity) dengan opsi majority vote.
- Fungsi predict_outcome(query) menghasilkan solusi prediksi + 5 case_id rujukan.

- Output: data/results/predictions.csv (query_id, predicted_solution, top_5_case_ids).

Tahap 5 — Model Evaluation (05_evaluation.py)

- Evaluasi klasifikasi (Accuracy, Precision, Recall, F1) + classification report + confusion matrix.
- Evaluasi retrieval (Accuracy@5, Precision@5, Recall@5, F1@5).
- Evaluasi prediksi solusi (Hit Rate@5) dari queries.json.
- Analisis kegagalan (error analysis) + rekomendasi perbaikan + bar chart perbandingan model.
- Output: retrieval_metrics.csv, prediction_metrics.csv, error_analysis.csv, confusion_matrix.png, model_comparison.png.

BAB 4 HASIL DAN EVALUASI

4.1 Evaluasi Klasifikasi (test set, n = 18)

Model	Accuracy	Precision (w)	Recall (w)	F1 (w)	Macro-F1
TF-IDF + SVM (LinearSVC)	0.8889	0.9060	0.8889	0.8796	0.89
TF-IDF + Naive Bayes	0.9444	0.9491	0.9444	0.9426	0.95

Classification report — Naive Bayes (model terbaik):

Kelas	Precision	Recall	F1	Support
dikabulkan	1.00	0.80	0.89	5
ditolak	0.92	1.00	0.96	11
lainnya	1.00	1.00	1.00	2

4.2 Evaluasi Retrieval (top-k = 5)

Model	Accuracy@5	Precision@5	Recall@5	F1@5
TF-IDF + Cosine	1.000	0.7444	0.1080	0.1775
BERT + Cosine	0.8333	0.6444	0.0827	0.1409

Catatan metrik retrieval: ground-truth relevan didefinisikan sebagai seluruh kasus berlabel sama. Karena satu kelas bisa berisi puluhan dokumen sementara hanya 5 yang diambil, Recall@5 secara struktural rendah (mis. kelas ditolak punya ± 57 relevan $\rightarrow$ recall maksimum $\approx 0,09$). Oleh karena itu Precision@5 dan Accuracy@5 lebih informatif untuk menilai retrieval ini.

4.3 Evaluasi Prediksi Solusi (Tahap 4)

- Dari 10 query uji, prediksi weighted similarity benar pada 6 dari 10 kasus; kesalahan terjadi pada pasangan kategori yang mirip (Lain-lain $\leftrightarrow$ Tidak Dapat Diterima).
- Hit Rate@5: TF-IDF = 1,0; BERT = 0,9 (lihat keterbatasan butir 5.2).

4.4 Analisis Kegagalan (Error Analysis)

- Total kesalahan SVM di test set: 2 kasus, keduanya berlabel asli dikabulkan namun diprediksi ditolak.
- Rata-rata panjang dokumen yang gagal ± 6.819 kata $\rightarrow$ dokumen sangat panjang menyulitkan model membedakan kelas minoritas.
- TF-IDF (statistik kata) mengungguli BERT generik pada domain ini, karena all-MiniLM-L6-v2 tidak dilatih khusus bahasa hukum Indonesia.

BAB 5 KETERBATASAN DAN REKOMENDASI

5.1 Keterbatasan

- Ketidakeimbangan kelas: ditolak mendominasi ($\pm 64\%$), kelas lain sedikit sehingga pola minoritas kurang dikenali.
- Kualitas label: decision_type diturunkan dari pencocokan kata pada teks penuh sehingga rawan noise (mis. kata 'ditolak' pada konteks eksepsi).
- Dokumen non-substantif: sebagian dokumen berupa penetapan/pencabutan gugatan yang tidak memuat amar pokok perkara.
- BERT generik: belum di-fine-tune untuk domain hukum Indonesia.

5.2 Catatan Metodologis untuk Iterasi Berikutnya

- Hit Rate@5 = 1,0 bersifat optimistis karena queries.json dibangun dengan retrieval ke seluruh dokumen termasuk dokumen query sendiri (self-retrieval). Sebaiknya kecualikan dokumen query dari hasil retrieval.
- Pelatihan TF-IDF: vectorizer sebaiknya di-fit hanya pada data train (bukan seluruh data) untuk menghindari kebocoran kosakata.

5.3 Rekomendasi Perbaikan

1. Augmentasi/penyeimbangan data kelas minoritas (mis. SMOTE atau menambah putusan dari pengadilan lain).
2. Feature engineering eksplisit dari pasal dan identitas pihak sebagai fitur kategoris.
3. Fine-tuning IndoBERT (indobenchmark/indobert-base-pl) pada korpus hukum.
4. Mekanisme rejection: bila similarity tertinggi < ambang (mis. 0,3), sistem menyatakan tidak ada padanan yang cukup mirip.
5. Ensemble TF-IDF+SVM/NB dengan BERT melalui weighted voting.

BAB 6 KESIMPULAN

Sistem CBR untuk analisis putusan PMH PN Bandung berhasil diimplementasikan secara end-to-end sesuai siklus CBR. Dari 131 dokumen yang dikumpulkan, 90 putusan valid membentuk case base. Pada tahap retrieval/klasifikasi, TF-IDF + Naive Bayes memberikan performa terbaik dengan Accuracy 0,94 dan F1 0,94 (macro-F1 0,95), mengungguli SVM maupun retrieval berbasis BERT generik. Tahap reuse mampu memprediksi solusi (amar putusan) kasus baru dari kasus termirip. Keterbatasan utama berupa ketidakseimbangan kelas dan kualitas label membuka peluang perbaikan melalui penyeimbangan data, fitur kategoris, fine-tuning model bahasa hukum, serta mekanisme rejection.

LAMPIRAN — Cara Menjalankan (ringkas)

```
pip install -r requirements.txt
python 01_scraping.py           # Tahap 1: scraping + cleaning
python 02_qa_check.py           # QA case base (opsional)
python 02_representation.py     # Tahap 2: representasi
```

```
python 03_retrieval.py      # Tahap 3: retrieval + model
python 04_predict.py       # Tahap 4: solution reuse
python 05_evaluation.py    # Tahap 5: evaluasi
```